



طراحی و ساخت سیستم هوشمند ارائه توضیحات متنی در خصوص تصمیمات وسایل نقلیه خودران

Design and Implementation of an AI explanation system for self-driving vehicle decisions



پایان نامه کارشناسی ارشد مهندسی کامپیوتر

گرایش هوش مصنوعی و رباتیکز


استاد راهنما: دکتر محمدجواد رشتی

استاد مشاور: دکتر سید عنایت اله علوی

پاییز ۱۴۰۴




فهرست مطالب



- طرح مساله
 - توضیح پذیری
 - محیط اجرا
- روش های پیشین
 - کیم و همکاران (۲۰۱۸)
 - DriveGPT4 (۲۰۲۴)
 - ADAPT (۲۰۲۳)
- روش پیشنهادی
 - بلوک دیاگرام مدل تصمیم گیر
 - بلوک دیاگرام مدل توضیح دهنده
 - پرامپت استفاده شده در مدل زبانی
- اهداف پژوهش
- روش ارزیابی
- آموزش و بررسی مدل تصمیم گیر (ADAPT)
- آموزش و بررسی مدل توضیح دهنده
- پیشنهادهای پژوهشی آینده

طرح مساله: توضیح پذیری

- هوش مصنوعی توضیح پذیر (XAI): مجموعه‌ای از روش‌ها و تکنیک‌ها در یادگیری ماشین که هدف آن‌ها تبیین دلایل تصمیم‌گیری مدل‌های پیچیده و کاهش خاصیت «جعبه‌سیاه» بودن آن‌ها است.



- روش‌های مرسوم توضیح پذیری و محدودیت آن‌ها
- پس معمولاً در مسائل پیچیده‌تر توضیحات متنی مناسب‌تر است



تصمیم: کاهش سرعت

توضیح متنی: به دلیل
اینکه خودروی روبرو
سرعت خود را کاهش
داده است




Action description: The car is stopped **Action justification:** for the red light




Action description: The car pulls into the right lane
Action justification: because traffic is moving faster in that lane.


روش های پیشین: کیم و همکاران (۲۰۱۸)




روش های پیشین: DriveGPT4 (۲۰۲۴)




روش های پیشین: ADAPT (۲۰۲۳)




(a) Overall Architecture



(b) Motion Prediction Head



(c) Text Generation Head




روش های پیشین


نویسنده	هدف	روش	مزایا	معایب	معیار ارزیابی	مجموعه داده	نوع داده
کیم و همکاران (۲۰۱۷)	تشخیص زاویه فرمان	CNN, LSTM	دقت بالا		MAE	Comma.ai,Udacity , HCE	ویدیو
کیم و همکاران (۲۰۱۸)	توضیح متنی برای تصمیم مدل	شبکه کانولوشن و شبکه عصبی	عدم نیاز به مدل جداگانه برای استخراج ویژگی	توضیحات محدود و نیاز به داده آموزشی زیاد ،روش ارزیابی نامناسب	نظر سنجی	BDD-X	ویدیو
جین و همکاران (۲۰۲۳)	توضیح متنی برای تصمیم مدل	Transformer	دقت بالا در تصمیم گیری	دقت پایین در توضیح دهنده	BLEU-4, ROUGE-L, METEOR, CIDER	BDD-X	ویدیو
باتاچارجی و همکاران (۲۰۲۳)	توضیح متنی برای تصمیم مدل	text-davinci-003 GPT-3.5 GPT-4	توضیحات پویا روش ارزیابی الگوریتمی	نیاز به ورودی متنی	LFS, USE	IMDB, AG News, SNLI	متن
چن و همکاران (۲۰۲۳)	توضیح متنی برای تصمیم مدل	توضیح پذیری انتها به انتها	توضیحات متنی کامل و قابل فهم	دقت پایین تصمیم گیری	نظرسنجی (انسانی و GPT Score)	DQA	تصویر
ماورپیس و همکاران (۲۰۲۴)	تبدیل خروجی XAI به توضیحات متنی	GPT-4	قابلیت استفاده در مدل های متنوع	نیاز به خروجی XAI ، روش ارزیابی نامناسب	نظرسنجی	SHAPley, fake news, SMV	تصویر/متن

روش پیشنهادی

- مشکلات روش های انتها به انتها
- راه حل: تفکیک مدل تصمیم گیر و توضیح دهنده



روش پیشنهادی: بلوک دیاگرام مدل تصمیم گیر




روش پیشنهادی: بلوک دیاگرام مدل توضیح دهنده

۷۲۰×۷۲۰




فریم های
استفاده شده



۲۲۴×۲۲۴

Attention
Map




Action: توقف خودرو

پرامپت

مدل زبانی بزرگ (LLM)

Justification: زیرا
عابر در حال عبور از خط
عابر پیاده است



۷۲۰×۷۲۰

روش پیشنهادی: پرامپت استفاده شده در مدل زبانی

نقش

شما یک سامانه توصیف‌گر در سناریوهای رانندگی هستید.

وظیفه

وظیفه شما دریافت تصویر یک سناریوی رانندگی، تصمیم اتخاذشده، و ناحیه موردعلاقه سامانه تصمیم‌گیر است؛ سپس توضیح دهید چرا سامانه تصمیم‌گیر آن تصمیم را اتخاذ کرده است.

داده ورودی

ورودی شما { {تعداد فریم} } فریم از دوربین جلوی وسیله نقلیه است که در آن ناحیه موردعلاقه با یک دایره قرمز مشخص شده است.

قالب و سبک خروجی

به صورت ساده و کوتاه و بدون حاشیه‌پردازی، تنها در ۱ یا ۲ جمله کوتاه توضیح دهید. از افزودن جملات اضافه، درخواست اطلاعات بیشتر و مانند آن خودداری کنید؛ زمینه کلی یا اطلاعات داده‌شده ورودی را شرح ندهید.

زمینه اطلاعاتی

شما به تمامی اطلاعاتی که سامانه تصمیم‌گیر در اختیار دارد دسترسی ندارید؛ بنابراین تصمیم اتخاذشده را صحیح فرض کنید.

محدودیت‌ها


به هیچ وجه بیش از ۲ جمله ننویسید.
از نوشتن عبارت‌هایی مانند «بر اساس تصویر ارائه‌شده...» یا «در نتیجه...» خودداری کنید.

مثال‌های راهنما

نمونه‌هایی از قالب مطلوب:



- چون کامیون جلویی سریع حرکت نمی‌کرد.
- چون چراغ سبز است.
- به دلیل خودرویی در جلو که هنگام پیچیدن به راست آهسته حرکت می‌کند.

اهداف پژوهش




- توسعه یک مدل تصمیم‌گیر برای وسایل نقلیه خودران با استفاده از داده‌های تصویری
- شناسایی مهم‌ترین فریم‌ها و نواحی توجه مدل تصمیم‌گیر با استفاده از نقشه توجه.
- اتصال خروجی مدل تصمیم‌گیر به ورودی مدل زبانی بزرگ جهت تولید توضیحات متنی.
- مقایسه عملکرد مدل‌های مختلف (LLM مانند ChatGPT و Gemini) در تولید توضیحات متنی از تصمیمات خودران.
- بررسی تأثیر Fine-Tuning بر کیفیت توضیحات تولیدی.





تولید کپشن های اضافی

- خودرو به راست می پیچد زیرا عابر پیاده در حال عبور است.
- خودرو برای احتیاط به سمت راست منحرف می شود چون یک عابر پیاده از خیابان عبور می کند.
- ماشین به سمت راست متمایل می شود، چرا که عابری در حال گذر از عرض خیابان است.




تولید کپشن های اضافی


نقش	شما یک سیستم تولید زیرنویس برای سناریوهای رانندگی هستید.
وظیفه	وظیفه شما این است که دو زیرنویس را دریافت کنید: یکی توصیف یک اقدام و دیگری ارائه دلیل برای آن اقدام. از هر زیرنویس، چهار زیرنویس دیگر تولید کنید که همان معنا را منتقل کنند اما از عبارات متفاوتی استفاده کنند.
داده ورودی	ورودی شما یک شیء JSON خواهد بود که شامل زیرنویس اصلی «اقدام» و زیرنویس «دلیل» است. زیرنویس اقدام توصیف می کند که سیستم رانندگی چه کاری انجام می دهد، در حالی که زیرنویس دلیل توضیح می دهد چرا آن تصمیم گرفته شده است.
قالب و سبک خروجی	زیرنویس ها باید ساده و مختصر باشند، تنها در یک یا دو جمله کوتاه بیان شوند، مشابه زیرنویس های اصلی. از افزودن توضیحات اضافی، درخواست اطلاعات بیشتر یا هرگونه زمینه خودداری کنید.
مثال های راهنما	برای مثال: • زیرنویس اصلی: «ماشین در تقاطع به چپ می پیچد». • زیرنویس تولیدشده: «ماشین به سمت چپ می چرخد.» این فرمت درست است زیرا معنا را حفظ می کند بدون افزودن جزئیات نادرست. اگر زیرنویس اصلی «اقدام» یا «دلیل» null باشد، برای آن بخش نیز null برمی گردانید. اینجا یک نمونه از ظاهر ورودی و خروجی است: • ورودی: {'action': 'ماشین با سرعت ثابت حرکت می کند', 'justification': 'چون ترافیک روان است'}. • خروجی: {'action': 'ماشین به جلو حرکت می کند', 'justification': 'ماشین به رانندگی ادامه می دهد', 'ماشین در جاده حرکت می کند', 'ماشین با سرعت عادی رانندگی می کند'}, {'justification': 'چون خیابان خلوت است', 'چون جاده باز است', 'زیرا جاده پیش رو خلوت است', 'چون مسیر روان است'}.



آموزش و بررسی مدل تصمیم گیر (ADAPT)



نمودار تابع زیان بر حسب دوره حین آموزش



- باز آموزی مدل ADAPT
- تغییر دیتا با کمک مدل زبانی
- روش ارزیابی (تک مرجع)

زمان آموزش (دقیقه)	BLEU-4	METEOR	ROUGE-L	CIDEr	SPICE	
۶۲۱	۳۵	۲۹.۲	۶۱.۶	۲۳۷.۶	۶۰	آموزش دوره ۶
۱۵۳۶	۳۳.۱	۲۹.۲	۶۱.۶	۲۱۷.۴	۵۷.۶	آموزش دوره ۱۶
۲۸۷۵	۳۳.۸	۲۹.۳	۶۱.۹	۲۳۴.۷	۵۹.۶	آموزش دوره ۲۶
۷۹۷	۳۴.۶	۳۰.۶	۶۲.۷	۲۴۶.۷	۵۹.۷	خط پایه ADAPT



آموزش و بررسی مدل توضیح دهنده




- مدل های زبانی Gemini 2.5 Pro, Gemini 2.5 Flash, Gemini 2.5 Flash-Lite و GPT-5 Mini به صورت خام و فقط با پرامپت گفته شده مورد استفاده قرار می گیرد.
- روش ارزیابی تک مرجع و چند مرجع
- برای هر مدل، ارزیابی در پنج سطح ورودی $n \in \{1, 4, 8, 12, 16\}$ که n نشان دهنده تعداد n فریم اول هر ویدیو (از ۱۶ فریم) است، انجام می شود.
- برای بهبود کیفیت خروجی های مدل توضیح دهنده، عمل Fine-Tuning روی مدل های Gemini 2.5 Pro و GPT-4o انجام می شود.


Fine-Tuning: یک مدل از پیش آموزش دیده که بر روی حجم عظیمی از داده های عمومی آموزش دیده است، برای یک وظیفه خاص و با استفاده از مجموعه داده ای کوچکتر و تخصصی تر، بازآموزی یا تطبیق داده می شود.

آموزش و بررسی مدل توضیح دهنده: Fine-Tuning روی مدل GPT-4o

نمودار تابع زیان حین FT مدل GPT-4o




نمودار دقت حین FT مدل GPT-4o




آموزش و بررسی مدل توضیح دهنده: Fine-Tuning روی مدل Gemini 2.5 Pro

نمودار دقت حین FT مدل Gemini 2.5 Pro



تابع زیان حین FT در Gemini 2.5 Pro



آموزش و بررسی مدل توضیح دهنده: نتایج تک مرجع

BLEU-4		CIDER-D		METEOR		ROUGE-L		SPICE		
امتیاز	n-best	امتیاز	n-best	امتیاز	n-best	امتیاز	n-best	امتیاز	n-best	
۱۱.۴	۳۲	۱۰۲.۶	۳۲	۱۵.۲	۳۲	۳۲	۱۶۳۲	۲۵.۶	۳۲	ADAPT
۱۰.۰۲	۸	۹۸.۷۱	۸			۳۱.۵۲	۸			DriveGPT4
۷.۰۸	۱۲	۶۲.۲	۱۲	۱۷.۷۲	۱۶	۳۲.۸۲	۱۲	۲۴.۳۵	۱۶	Gemini 2.5 Pro
۵.۶۴	۱۶	۵۴.۴	۴	۱۶.۸۴	۱۶	۳۱.۷۵	۱۶	۲۰.۰۶	۱۶	Gemini 2.5 Flash
۶.۸۸	۸	۶۰.۳۸	۱۶	۱۵.۳۳	۱۶	۲۹.۸۱	۸	۲۰.۵۱	۱۶	Gemini 2.5 Flash Lite
۲.۰۳	۱۶	۲۵.۴۸	۱۶	۱۴.۰۵	۱۲	۲۳.۲۹	۱۶	۱۱.۴	۱۶	GPT-5 mini
۱۱.۸۳	۱۲	۱۱۴.۷۳	۱۲	۱۹.۴۵	۱۲	۴۰.۵۷	۱۲	۲۸.۴۷	۱۲	FT-Gemini 2.5 Pro
۱۱.۰۹	۱۲	۱۰۳	۱۲	۱۵.۲۴	۱۲	۳۳.۸۴	۱۲	۲۶.۲۵	۱۲	FT-GPT-4o

آموزش و بررسی مدل توضیح دهنده: نتایج چند مرجع

BLEU-4		CIDER-D		METEOR		ROUGE-L		SPICE		
امتیاز	n-best	امتیاز	n-best	امتیاز	n-best	امتیاز	n-best	امتیاز	n-best	
۱۸.۴۵	۳۲	۹۵.۱۳	۳۲	۲۱.۰۲	۳۲	۴۷.۰۸	۱۶ و ۳۲	۱۸.۲۲	۳۲	ADAPT
۱۶.۰۸	۱۶	۵۹.۰۲	۱۶	۲۳.۸۱	۱۶	۴۸.۱۵	۱	۲۶.۶۳	۱۲	Gemini 2.5 Pro
۱۴.۰۹	۴	۵۳.۱۶	۱۶	۲۳.۱۸	۱۶	۴۷.۷	۱	۲۳.۵۴	۱۶	Gemini 2.5 Flash
۱۸.۰۷	۸	۵۳.۷۹	۱۶	۲۱.۳	۱۶	۴۵.۴۶	۸	۲۱.۲۱	۱۶	Gemini 2.5 Flash Lite
۶.۳۱	۱۶	۲۱.۶	۱۶	۱۹.۸	۱۶	۳۶.۵۳	۱۶	۱۵.۵	۱	GPT-5 mini
۲۳.۹	۱۲	۱۰۰.۷۵	۱۲	۲۴.۵۸	۱۲	۵۷.۵۹	۱۲	۲۷.۴۶	۱۲	FT-Gemini 2.5 Pro
۲۳.۶۵	۱۲	۹۵.۳۳	۱۲	۲۲.۲	۱۲	۵۴.۱۶	۱۲	۲۲.۷۵	۱۲	FT-GPT-4o

پیشنهادهای پژوهشی آینده

- ارزیابی انسانی کنترل شده: استفاده از روش های ارزیابی چون LFS و USE با داوران خبره/نیمه خبره و سنجه های شفاف
- مطالعه حذف مؤلفه ها برای کانتور توجه: اجرای سناریوهای «بدون کانتور»، «کانتور با آستانه/ضخامت متفاوت»، و «نمایش پیوسته نقشه توجه» و مقایسه نظام مندِ نتایج.
- پایداری و رُباست: سنجش حساسیت خروجی ها نسبت به تغییرات کوچک در دستور
- بهبود روش های یادگیری: بررسی اتصال های سبک وزن میان نمایش های بصری ADAPT و LLM (adapter/connector) یا آموزش مشترک محدود.
- اخلاق، حریم خصوصی و جانبداری: توسعه رویه های ناشناس سازی پایدار، پایش سوگیری های احتمالی در توضیح ها (مثلاً سوگیری نسبت به اشیاء/صحنه های خاص)

با سپاس از توجه شما

